

凸优化 CH 1 凸集和凸函数

凸集和凸函数

- 凸集（凸组合连线）
凸集的性质：交，加，仿射，水平集合是凸集
- 凸函数（凸组合的函数值）
典型的凸函数：指数，负对数，最小二乘，仿射，p范数
- 凸函数的一阶判定
 - $\forall x, x_0, f(x) \geq f(x_0) + \nabla^T f(x_0)(x - x_0)$
 - 直观理解：切线总在下面
- 凸函数的二阶判定（二阶导/Hessian矩阵:对称半正定、对称正定）
 - $\forall x, \nabla^2 f(x)$ 对称半正定
（正定： $\forall x, x^T A x \geq 0$ ，则称矩阵A是半正定的）
 - 直观理解：二次函数二次项系数大于0
 - 一个实例：标准型二次函数 $f(x) = \frac{1}{2} x^T p x + q^T x + r$
凹凸性：因为 $\nabla^2 f(x) = p$ ，所以判断p的正定性即可
- 凸函数的性质（“xx也是凸函数”）：
 - 非负系数线性和
 - 仿射复合： $f(Ax + b)$
 - 凸集上的下确界（降维，注意形式）
 - 任意集合上的上确界（降维，注意形式）
 - 共轭必凸（造凸函数的方法）
 - 几个凸函数取max
 - Jensen：线性组合（系数和为1，保内部），引申到概率
 - 透视函数（本质是将向量进行伸缩，规范化）

优化问题的标准形式

- 优化问题=目标函数（最小化）+不等式限制（不大于0）+等式限制（等于0）

$$\min f(x)$$

$$g_i(x) \leq 0, m \text{ 个}$$

$$h_j(x) = 0, n \text{ 个}$$
 一定注意是 \leq
- 有关概念
 - 可行解集X（由函数定义域和限制条件确定）
 - 局部极小解，全局极小解 \hat{x}
 - 最优值 p^* （下确界，不一定存在，一定唯一）
最优解 x^* （取最优值的解，不一定存在，不一定唯一）

凸优化问题的一般形式

针对上述的标准格式：

- $f(x)$ 是凸函数
- $h(x)$ 是仿射函数，等式条件可表述为 $Ax = b$
- 可行解集是凸集（若可行解集只由不等条件确定，则可行解集是水平集合的交，必为凸集）

简单、常见的优化问题的解

- 线性规划：目标、限制为线性，有可行解，非分析， $O(n^2m)$
- 二次规划：目标为二次，限制为 $Ax = b$ 和 $x_i > 0$
- 二次规划之最小二乘（点积最小）：有可行解，分析， $O(n^2m)$
- 有限制的最小二乘问题

凸优化问题最优解的性质

- 凸优化问题：局部极小=全局极小（性质不错）
凸优化问题利用这些性质判定解
- 无限制：（充要）梯度为0
- 等式限制：（KKT方程的解） $\nabla f_0(x^*) + A^T v^* = 0$

优化问题的等价转换

换一种表示方式->化简问题/有助于利用定式求解问题

- 上界，极小化，等效凸问题
- 减少约束个数：消除等式约束，消除线性约束
- 约束仿射化/松弛变量：简化思路，一个应用是SVM
- 变量独立化：使约束条件具有更好的结构
- 优化部分变量：可以利用确界降维优化函数，如约束条件维数低等情况
- 具体优化：最小化1范数、最小化无穷范数
- 优化表示：可行解问题、局部最优解问题

凸优化 CH 2 对偶与最优性条件

拉格朗日函数

- 拉格朗日函数： $L(x, \lambda) = f(x) + \lambda^T g(x)$
带等式约束： $L(x, \lambda) = f(x) + \lambda^T g(x) + v^T h(x)$
 - 拉格朗日对偶函数 $L_D(\lambda) = \inf_x L(x, \lambda)$
带等式约束： $L_D(\lambda, v) = \inf_x L(x, \lambda, v)$
 - 性质
 - $L_D(x)$ 是凹函数
 - $\lambda \geq 0$ 时，对偶函数是原函数的下界
 - $L_D(\lambda) = -f^*(-\lambda)$
(共轭函数： $f^*(\lambda) = \sup_{x \in \text{dom} f} (\lambda^T x - f(x))$ ，即 $f(x)$ 与 x 的线性函数的最远距离)
- 因为共轭函数必为凸函数，所以此性质也说明 $L_D(x)$ 是凹函数

拉格朗日对偶问题

$$\max L_D(\lambda, v)$$

$$\lambda \geq 0$$

弱对偶和强对偶

- 原函数： $L_P(x) = \sup_{\lambda \geq 0} L(x, \lambda)$
 $\min L_P(x)$ 和原问题等价（见纸质推导1）
- 弱对偶（极大极小不等式）：

$$\begin{aligned} \min_x L_P(x) &= \min_x \max_{\lambda} L(x, \lambda, v) \\ &\geq \max_{\lambda} \min_x L(x, \lambda, v) \\ &= \max L_D \end{aligned}$$

对偶问题的解是原问题解的下界

启发：求解原问题时可以先求解对偶问题（凸优化问题），对偶问题的解必定不大于原问题的最优解（给出下界，保底）

- 强对偶：上述不等式等号严格成立
一种很理想的情况，此时对偶问题的解就是原问题的解（纸质推导2）。
解释：极大极小不等式的鞍点
凸优化问题往往能满足强对偶条件。
- 强对偶的成立条件：Slater约束品性（内点）
存在可行解集的内点严格满足不等式条件（严格 $<$ ）
解释：对应有严格凸子集的凸集

KKT方程

强对偶性成立时的充要条件：原问题的解是KKT方程的解

$g(x) \leq 0, h(x) = 0$ (约束条件)

$\lambda \geq 0$ (v 没有要求)

$\lambda^T g(x) = 0$ (对 $g(x)$ 的松弛约束)

$\nabla f(x) + \lambda^T \nabla g(x) + v^T \nabla h(x) = 0$ (主方程)

凸优化 CH 3 通用下降方法

准备工作

问题描述

目标函数是至少二阶连续可导的凸函数

性质：最优解充要于梯度为0，且水平集合为闭集

二阶泰勒近似：

$$f(x) = f(x_0) + \nabla^T f(x_0)(x - x_0) + \frac{1}{2}(x - x_0)^T \nabla^2 f(x)(x - x_0)$$

经常用这个式子直接相等时的情况做估计，以下的迭代求解都基于等式

强凸性

- 定义

$\exists m > 0, s.t. \nabla^2 f(x) \geq mI, \forall x \in \text{dom } f$ ，即二阶梯度（Hessian矩阵）有正的下界

- 上部限界（经常成立）：

$$mI \leq \nabla^2 f(x) \leq MI$$

估计m和M的好方法:矩阵的最大最小特征值

- 性质：

- 结合二阶展开的等式使用

$$f(x) \geq f(x_0) + \nabla^T f(x_0)(x - x_0) + \frac{m}{2} \|x - x_0\|_2^2$$

- 目标函数值与最优值（最小值的差）由梯度限定

$$e(x) = f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

因此，通用下降方法可以判断梯度作为停止条件

无约束最小化方法：通用下降方法

求解无约束问题使用基于迭代的方法，取一点的序列以逼近梯度为0的点

```

find x # 取初值点
while |gradient x|>e # 有时也会采取不是梯度范数的其他停止条件
# 有时这里也用|gradient x|>2me, e对应原函数误差
    find d # 找下降方向d
    # 下降方向：梯度与方向内积<0, 即局部一阶凸
    find t # 找下降步长t
    # 下降步长：只要使函数值下降即可, 即f(x+td)<f(x)
    upgrade x: x=x+td
end

```

- 以下记原始误差 $e_0 = e(x_0) = f(x_0) - p^*$ 。下文讨论收敛性时，实际讨论的 e 也是达到 $f(x) - p^* < e$ 的情况,不是函数梯度模的 e 。算法中用梯度表示迭代停止的停止阈值对应这里的 $2me$ 。
- 这里梯度没有要求具体是哪个范数，不过回溯下降和2范数联系紧密，这里最好采取2范数；最速下降最好采取和最速方向确定相同的范数。牛顿下降使用的是牛顿减小量。

线性下降方法介绍

确定下降方向的办法

- 梯度下降：取负梯度方向为下降方向
- 最速下降：基于方向导数，找下降速度最快的方向

$$d_{nsd} = \operatorname{argmin}\{\nabla^T f(x) * d, s.t. ||d|| = 1\}$$

在下文最速下降部分，没有特殊声明的范数（没有下标的范数 $|| \cdot ||$ ）就是梯度在此处的范数，下标为*的范数 $|| \cdot ||_*$ 是其对偶范数

最速下降：一些补充

- 最速下降方向使方向导数最小（绝对值最大的负值）
- 最速下降方向是单位方向
- 非规范化最速下降：最速下降方向*梯度的对偶范数

$$d_{sd} = d_{nsd} * ||\nabla f(x)||_*$$

- 一些特殊情况
 - 2范数：非规范化最速下降方向就是负梯度方向
 - 1范数：等价于每步只改动梯度最大分量的维度，往下降方向（正或负）走 $\frac{\partial f}{\partial x_i}$ （当前点的偏导数）

- 梯度和最速的重要区别：最小化的参考标准不同

$$\nabla^T f(x) * d = -||d||_2^2$$

$$\nabla^T f(x) * d_{sd} = -||d_{sd}||_*^2$$

如果最速下降采用2范数，则确定的下降方向就是负梯度方向

确定下降步长的方法

- 精确直线搜索：针对步长 t 做单变量优化 $\min_{t>0} f(x + td)$ ，找到精确的最小值
- 回溯直线搜索：先取步长 $t = 1$ ，然后每次乘一个公比 $\beta < 1$ 来缩
回溯停止条件： $f(x + td) < f(x) + \alpha \nabla^T f(x) * td, 0 < \alpha < 0.5$

回溯直线：一些补充

- $\nabla^T f(x) * td$ 对应目标函数在下降方向上的方向导数
后文可以看到，有时方向导数的数值比较容易通过其他量计算得到，此时也会用跟其他量有关的表达式表示，但实质是一样的
- 参数 α, β 的作用
 - α 的作用： $\nabla^T f(x) * td$ 是负的，而 $f(x + td) \rightarrow f(x) + \nabla^T f(x) * td, t \rightarrow 0$ ，由此可知 α 的作用是规定步长不能太小，同时也保证下降性
 - β 的作用： β 较大时内部迭代次数较多（用于确定步长的计算量较大），但估计得到的步长较好，外部迭代次数少；较小刚好相反。
- 实际应用时注意检查 $x + td$ 是否在定义域内

线性下降方法的收敛性分析

通用收敛性证明

- 所谓线性下降，就是误差近似等比地减小
- 每次迭代，下降不小于 $\mu \|\nabla f(x)\|_2^2$

$$f(x_k) - f(x_{k+1}) \geq \mu \|\nabla f(x_k)\|_2^2$$

- 第 k 次迭代，误差 $e_k \leq c^k e_0$

$$f(x_k) - p^* = e_k \leq c^k e_0 = f(x_0) - p^*$$

这里的 c 由估计值下界公式算出， $c = 1 - 2m\mu$

- 收敛到误差 e ，所需步数 $K \geq \left\lceil \frac{\log(e_0/e)}{\log(1/c)} \right\rceil = -\frac{\log(e_0/e)}{\log(c)}$

梯度下降+精确直线搜索

- $\mu = \frac{1}{2M}$ ，由强凸性易证
 $c = 1 - m/M$
- 收敛到误差 e ，所需步数 $K \geq \left\lceil \frac{\log(e_0/e)}{\log(1/c)} \right\rceil$
- 步长 K 估计值 $\frac{\log(e_0/e)}{-\log(1-m/M)} \rightarrow \frac{\log(e_0/e)}{m/M}$ ，故收敛步数大约正比于 M/m ，即收敛速度很强地线性依赖于 M/m

梯度下降+回溯直线搜索

- $\forall t \leq \frac{1}{M}$ 满足回溯停止条件
因此，每一步回溯直线搜索要么 $t=1$ ，要么 $t \geq \frac{\beta}{M}$
- $\mu = \alpha \min(1, \frac{\beta}{M})$ ，由回溯终止条件直接指出的
 $c = 1 - 2m\alpha \min(1, \frac{\beta}{M})$
- 步数大约正比于 M/m (收敛速度很强地线性依赖于 M/m)

最速下降+精确直线搜索

- 约束/参数：原范数，对偶范数至少是2范数的 γ ， $\tilde{\gamma}$ 倍
 $\|\cdot\| \geq \gamma \|\cdot\|_2, \|\cdot\|_* \geq \tilde{\gamma} \|\cdot\|_2$
- $\mu = \frac{1}{2M}$ ，爆算+针对2范数合理放缩（见作业）
计算结果和梯度+精确一样，过程却有所不同，很有意思
 $c = 1 - m/M$

最速下降+回溯直线搜索

- 参数： $\gamma, \tilde{\gamma}$
- 估计步长： $t \leq \frac{\gamma^2}{M}$ 时回溯停止条件满足，每步收敛步长 $t \geq \min(1, \beta \frac{\gamma^2}{M})$
- $\mu = \alpha \tilde{\gamma}^2 \min(1, \frac{\beta \gamma^2}{M})$ ，步骤和梯度+回溯完全对应，针对2范数有一个系数放缩
- $c = 1 - 2m\alpha \tilde{\gamma}^2 \min(1, \frac{\beta \gamma^2}{M})$

非线性下降方法（牛顿方法+回溯直线搜索）

- 下降方向
 $d_{nt} = -\nabla^2 f(x)^{-1} \nabla f(x)$
意义：二阶泰勒展开最小值/Hessian矩阵范数
下降性证明：因为二阶梯度是正定的，所以 $\nabla^T f(x) d_{nt} = -\nabla^T f(x) \nabla^2 f(x)^{-1} \nabla f(x) < 0$
- 牛顿减小量
 $\lambda = (\nabla^T f(x) \nabla^2 f(x)^{-1} \nabla f(x))^{1/2}$
 $\lambda^2 = d_{nt}^T \nabla^2 f(x) d_{nt}, \lambda^2 = -\nabla^T f(x) d_{nt}$
迭代停止： $\lambda^2 < e$
- 回溯直线搜索
回溯停止条件： $f(x + t d_{nt}) < f(x) - \alpha t \lambda^2$
实际上 $\lambda^2 = -\nabla^T f(x) d_{nt}$ ，停止条件和之前的回溯直线搜索是对应的。
- 收敛性分析（具体看作业）
 - 前提：F范数（方均根范数，Frobenius范数）Lipschitz连续

$$\|\nabla^2 f(x) - \nabla^2 f(x_0)\|_F < L \|x - x_0\|_2$$

L可以解释为三阶导数的界，在L较小时牛顿法表现较好

- 阻尼牛顿：存在 $0 < \eta \leq \frac{m^2}{L}$ 使得
在 $\|\nabla f(x)\|_2 > \eta$ 时, 每次至少下降 γ
证明思路：固定 η 并正常估计步长，计算每一步下降量来估计 $\gamma = \alpha \beta \eta^2 \frac{m}{M^2}$
- 二次收敛：在 $\|\nabla f(x)\|_2 < \eta$, 每一步都有 $\|\nabla f(x_{k+1})\|_2 < \frac{L}{2m^2} \|\nabla f(x_k)\|_2^2$
证明思路：证明步长为1（利用L，梯度差换变量形成二阶导，函数积分2次），爆算估计 $\eta = \min(1, 3(1 - 2\alpha)) \frac{m^2}{L}$ ，顺便证明了二次收敛性

凸优化 CH 4 等式约束问题

问题描述

- $\min_x f_0(x)$
s.t. $Ax = b$
- $f_0(x)$ 是至少二阶连续可导的强凸函数
- 等式约束中 A 是 $p \times n$ 维矩阵（ n 是变量的维数）
 A 是满秩的, $\text{rank } A = p$
- $h(x) = Ax - b, \nabla h(x) = A$

直接求解

- 理论上可以直接列解KKT方程来求解问题：存在最优解 x^* 等价于如下的方程组有解

$$\begin{cases} Ax^* = b \\ \nabla f(x^*) + v^{*T} A = 0 \end{cases}$$

不难发现 $v^* = -(AA^T)^{-1} A \nabla f(x^*)$ ，这个结果后文有用

- 一个特殊情况

对于二次函数求解，KKT方程可以写成矩阵形式：

$$\begin{bmatrix} P & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ v \end{bmatrix} = \begin{bmatrix} -Q \\ b \end{bmatrix}$$

对后文的迭代求解有指导意义

- 大多数情况，KKT方程很难直接求解

破坏原问题结构求解

消除等式约束

- 对 x 进行仿射以降维，使 p 个等式约束被化解，形成的新变量为 $n-p$ 维无约束变量

$$\{x : Ax = b\} = \{Fz + \hat{x} : z \in \mathbb{R}^{n-p}\}$$

\hat{x} 是特解， $A\hat{x} = b$

F 是 A 的零空间中的矩阵， $n \times (n-p)$ 维， $AF = 0$

注：变成无约束问题之后就没有KKT方程了，因为不再有对偶

- F 的无关性
任何一个零空间内的矩阵都可用作消除矩阵
消除矩阵乘以一个满秩的矩阵还是消除矩阵

对偶方法求解

直接列出对偶问题并求解

$$\max_v -b^T v - f^*(-A^T v)$$

迭代求解

牛顿+回溯 从可行点开始

- 额外要求：从可行点 $Ax_0 = b$ 开始；每一步下降都可行，即 $Ad_{nt} = 0$
- 牛顿方向的选取：满足方程

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

- 讨论
 - 跟二次函数对应，可以还用之前二阶泰勒来解释
 - 可以解释成最优性条件的线性近似方程组的解
- 性质
 - 可以保住之前的一切关于收敛性的计算结果（减小量定义、阻尼、二次、各个数值）
 - 仿射不变性： $x = Ty$ ，则 $d_{x,nt} = Td_{y,nt}$
可以回代看看牛顿方向的定义方程是怎么变的
这种换元可以让我们选取合适的 T 来简化计算
 - 从可行点开始牛顿，每步迭代过程和消除等式约束+无约束牛顿完全相同，即牛顿方向相同（乘个 F ），减小量相同，下一个序列点相同
证明：根据仿射不变性，对应着算

牛顿+回溯 从不可行点开始

- 问题转化：最优化对偶残差

$$r \begin{pmatrix} x \\ v \end{pmatrix} = \begin{bmatrix} r_{dual}(y) & = & \nabla f(x) + A^T v \\ r_{pri}(y) & = & Ax - b \end{bmatrix}$$

，通过迭代使其下降到0（满足可行点的KKT）

- 牛顿方向的选取：尽快完成对偶残差的最优化，使得

$$r \begin{pmatrix} x + d_x \\ v + d_v \end{pmatrix}$$

下降最快

具体：牛顿方向应满足方程

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ Ax - b \end{bmatrix}$$

理解：对应可行牛顿方向选取的线性近似理解，在迭代格式中 $r_{pri}(y_k + d_{y,k})$ 的值应由上一次迭代的中心残差计算得到，所以约束条件的迭代格式写为 $Ad_{x,k} = Ax_k - b$ ，其中 $d_{x,k}$ 决定了 $x_{k+1} - x_k$ （的方向）

- 回溯停止条件：利用残差的2范数

$$\|r(y + td_y)\|_2 > (1 - \alpha t)\|r\|_2, y = \begin{pmatrix} x \\ v \end{pmatrix}$$

此处使用 $\|r\|_2$ 是因为 r 在 d_y 方向上的方向导数为 $-\|r\|_2$ ，即 $t = 0$ 时 $\frac{d}{dt}(\|r(x + td_y)\|_2) = -\|r\|_2$ ，使用这个量对应回溯搜索中要求的方向导数

- 可行性

- 牛顿方向可以保证对偶残差的范数一直减小（在点处其2范数对步长 t 的导数是负的2范数），但是不能保证下降
因此，残差以指数速度下降（线性收敛），迟早会降为0
实际上残差方向一直不变，长度等比减小
- 残差降为0的标志：步长取得1，再往下都是可行方向可行点了，已经达到误差允许的范围
 $Ax - b = 0$ ，与可行牛顿无异；此时应该修改牛顿方向的计算和回溯停止条件，回归正常的牛顿
在下面的推导中没管这个误差，还是正常按设定误差算，经过两个阶段之后近似收敛到可行点，再按可行点牛顿下降来做
- 有的时候就是不可行

- 收敛性分析

- 要求和参数

- r 在初始点的水平集合 S 是凸集
- KKT的逆矩阵 $Dr(y)$ 有上界 K ，即 $\|Dr(y)^{-1}\|_2 \leq K$

- Lipschitz连续： $\|Dr(y) - Dr(y_0)\|_2 \leq L\|y - y_0\|_2$
- 这些条件可以保证最优解和相应的对偶变量一定存在
- 取 $t_{max} = \inf\{t > 0 : r(y + td_y) = 0\}$ ，有 $\|r(y + td_y)\|_2 \leq (1 - t)\|r(y)\|_2 + \frac{1}{2}K^2Lt^2\|r(y)\|_2^2, t \leq t_{max}$
- 阻尼牛顿阶段
 - 回溯牛顿停止条件： $t_k \leq \frac{1}{K^2L\|r(y_k)\|_2^2}$
每一步的上界因梯度而异，但不妨碍导出结果
 - 下降量： $\gamma = \alpha\beta\frac{K^2}{L}$
- 二次收敛阶段：
 - 阶段的参数： $\eta = \frac{1}{K^2L}$
 - 步长： $t = 1$
 - 二次收敛性： $\|r_{k+1}\|_2 \leq \frac{K^2L}{2}\|r_k\|_2$

凸优化 CH 5 等式不等式约束问题

问题描述

- $\min_x f_0(x)$
s.t. $f_i(x) \leq 0 (1 \leq i \leq m), Ax = b$
- $f_0(x)$ 是至少二阶连续可导的强凸函数
- 等式约束中A是p*n维矩阵（n是变量的维数）
A是满秩的, $rank A = p$
- $h(x) = Ax - b, \nabla h(x) = A$

不等条件的消解

示性函数

$$\text{示性函数 } I_-(u) = \begin{cases} \infty, & u > 0 \\ 0, & u \leq 0 \end{cases}$$

利用示性函数,问题转化为 $\min_x f_0(x) + \sum_{i=1}^m I_-(f_i(x)), s.t. Ax = b$ ，也是凸优化问题，也能给出同样的最优解

但我们希望目标函数性能能再好一点（可微）

对数障碍函数/近似示性函数

- 近似示性函数 $\hat{I}_-(u) = -\frac{1}{t} \log(-u)$ 对示性函数做了很好的模拟， t 取越大越好
使用对数障碍函数表示这个和， $\phi(x) = \sum_{i=1}^m -\log(-f_i(x))$
问题转化为 $\min_x t f_0(x) + \phi(x), s.t. Ax = b$ ，也是凸优化问题，也能给出同样的最优解
- 对数障碍函数的实质是把不等约束放宽到了 $f_i(x) \leq 1/t$ ，下文的中心路径法对应KKT方程的连续变形，最终逼近最优解及其KKT
- 参数为 t 的近似问题，求解误差上界为 m/t ，即 $p^*(t) - p^* \leq m/t$
(利用KKT和对偶函数性质证明)

障碍方法

- 直接求解
因为 t 可以控制求解精度，所以可以直接设定 t ，求解对应的问题来获得对应精度的解
问题： t 较大时 Hessian 矩阵在可行集边界上误差较大
- 障碍方法求解
针对一系列 t 解一系列问题，把每一个问题的结果作为下一个问题的初始点，直到 t 符合精度要求，求解结果序列称为中心路径
 t ：从 t_0 开始，以 μ 为公比的等比数列
- 阶段2：从满足等式不等式条件的点出发，求解中心路径，迭代求问题的解

寻找可行点（阶段1）

障碍方法需要从一个满足等式不等式条件的点出发，需要提前找这个点

阶段1对于平凡的初始点 x_0 设计一个子问题（等式不等式优化问题），执行障碍方法求解以获得下一阶段的初始点；因此，问题设计的重点是初始点必须可行

满足等式约束条件的 x_0

- 问题

$$\min_{s,x} s$$

$$s.t. f_i(x) \leq s, Ax = b$$
- 此问题总严格可行，因为 s 也是优化变量，相当于不等式约束是 $g_i(x, s) = f_i(x) - s \leq 0$ ，初始值 s_0 取 $\max(f_i(x_0))$ 即可
- 迭代到 $s < 0$ 说明有严格可行解，迭代到 $s > 0$ 说明解不存在，但获得的解已经是这种情况下能用的最好的解了，所以也没事

不满足等式约束条件的 x_0

- 对应不可行初始点的牛顿
- 先上松弛约束，把做不到的约束丢进目标函数，从而保证严格可行性，把不可行的部分变成优化目标；再通过迭代助教优化

$$\min_{z_i, s, x} t_0 f_0(x) - \sum_{i=1}^m \log(s - f_i(x))$$

$$s.t. Ax = b, s = 0$$

不位于可行解集的 x_0

- 对应不可行初始点的牛顿
- 思路还是为保证严格可行性而凑格式

$$\min_{s, x} t_0 f_0(x + z_0) - \sum_{i=1}^m \log(s - f_i(x + z_i))$$

$$s.t. Ax = b, s = 0, z_i = 0 (0 \leq i \leq m)$$

基于原对偶残差的搜索

- 对标等式约束的原对偶残差方法
- 减小量：原对偶残差，多了一个中心残差

$$r_t(x, \lambda, v) = \begin{bmatrix} r_{dual} \\ r_{cent} \\ r_{pri} \end{bmatrix} = \begin{bmatrix} \nabla f_0(x) + Df(x)^T \lambda + A^T v \\ \lambda f(x) - 1/t \\ Ax - b \end{bmatrix}$$

- 下降方向（对应等式约束的原对偶下降方向）

$$\frac{\partial r_t(x, \lambda, v)}{\partial(x, \lambda, v)} \begin{bmatrix} d_x \\ d_\lambda \\ d_v \end{bmatrix} = -r_t(x, \lambda, v)$$

- 参数 t : $t = \frac{\mu m}{\eta(x, \lambda)} = \frac{\mu m}{-Df(x)^T \lambda}$
- 各种停止的误差参数： r_{dual} 和 r_{pri} 用一个 $e_{feas}, \eta(x, \lambda)$ 用一个 e ，不知道啥意思

